

Parcial 1 Análisis Exploratorio, EDA de negocio AndinaExpress

Mariana Machado Echeverry, Daniel Pallares Kelin

1. Calidad y proceso de limpieza de los datos

En el archivo proporcionado podemos ver que contiene 1550 registros con 18 variables, las cuales nos hablan de zona, servicio, costo, calificación, etc. Encontramos 50 envíos duplicados, pudimos evidenciarlo a partir de la variable `id_envio`.

a. Criterios de decisión

Antes de tocar el archivo definimos tres reglas para no evitar corregir caso por caso.

Primero: Corregimos un dato cuando el negocio nos permite deducir cual era el valor real, por ejemplo, un envío con 38.860 Kg no es un envío que podamos considerar gigante, es un peso que alguien registro en gramos, ya que es un peso que alguien registro en gramos, aquí tiene sentido arreglarlo en lugar de borrarlo.

Segundo: Cuando el valor real no se puede conocer, dejamos la celda vacía. Nunca inventamos un número ni rellenamos el promedio, porque estaríamos fabricando información que no está presente dentro del archivo, por ejemplo, un tiempo de entrega de -999 es la forma del sistema de decir que no capturo el dato.

Tercera: Lo que a simple vista parece raro, pero es real, se queda. Los fletes negativos parecen un error hasta que se revisa el diccionario, donde se puede observar que en realidad son notas de crédito sin cumplir la promesa de tiempo de entrega. Si se borran habría escondido un costo que la operación si está asumiendo

b. Tabla de correcciones

Variable	Tipo	Hallazgo	Reg.	Decisión
<code>id_envio</code>	Duplicado	50 IDs repetidos ("Reintento de carga desde WMS")	50	Se elimina el duplicado
<code>ciudad</code>	Estandarización	30 grafías para 10 ciudades	calcular	Normalización a 10 ciudades
<code>transportadora</code>	Estandarización	14 grafías para 4 operadores	calcular	Normalización a 4 operadores
<code>devuelto</code>	Estandarización	14 codificaciones para una binaria	calcular	Unificación a Sí/No; 12 sin dato quedan vacíos
<code>fecha_despacho</code>	Formato	3 formatos distintos de fecha	1.5	Conversión a datetime
<code>costo_flete_cop</code>	Formato	237 valores en texto ("24.900")	237	Conversión a numérico
<code>fecha_despacho</code>	Fuera de rango	5 fechas imposibles + 6 fuera del trimestre	11	Se vacían

peso_kg	Fuera de rango	13 valores ≤ 0	13	Se vacían
peso_kg	Error de unidad	25 valores > 80 kg (límite contractual)	25	Se dividen entre 1.000
tiempo_entrega_h	Centinela	31 en -999 y 14 en 0	45	Se vacían
intentos_entrega	Fuera de rango	3 registros en 0	3	Se corrigen a 1
calificacion_cliente	Fuera de rango	9 fuera de la escala 1–5	9	Se vacían
cadena_frio	Inconsistencia lógica	9 marcados "No" con temperatura registrada	9	Se corrige el flag a "Sí"
costo_flete_cop	Valor atípico válido	5 montos negativos	5	Se conservan (nota de crédito)

c. Decisiones argumentadas


Pesos por encima de 80 kg: Aparecieron 25 registros que superan el límite contractual de 80 kg, uno de ellos con 38.860 kg. Antes de borrarlos probamos si estaban digitados en gramos: dividimos los 25 entre 1.000 y todos quedaron dentro del rango válido, sin excepciones. Que cuadre en el 100% de los casos es lo que nos convenció de que era un error de unidad y no valores sueltos mal digitados. Recuperamos los 25 envíos y el peso mediano quedó en 3,58 kg, coherente con paquetería de comercio electrónico.

Fletes negativos: Cinco registros tienen el flete en negativo. Parece un error de captura, pero el diccionario los define como notas de crédito por incumplir la promesa de entrega: es plata que la empresa devolvió al cliente por llegar tarde. Los dejamos tal cual, porque borrarlos habría maquillado el costo de la operación justo en los casos donde falló, que es lo último que conviene en un análisis para renegociar tarifas.

Cadena de frío: Nueve envíos están marcados como que no requerían cadena de frío pero tienen temperatura registrada, y según el diccionario esa temperatura solo se mide cuando el envío sí es refrigerado. Nos quedamos con la temperatura y corregimos el flag a "Sí": la temperatura la tuvo que tomar alguien físicamente, mientras que el flag es una casilla que se marca al digitar, mucho más fácil de equivocarse.


2. Responder a las preguntas de negocio

¿Qué tiempo de entrega puede prometer la empresa en su sitio web?




El tiempo de entrega que puede prometer su sitio web es de 73h, no usamos la media para promesas de servicio porque no se podría sustentar con los valores atípicos, la distribución tiene cola larga a la derecha, por lo que el promedio subestima el riesgo de incumplimiento. El uso del P90 es una medida de dispersión buena que además garantiza que la empresa cumplirá la promesa en 9 de cada 10 envíos, protegiendo la reputación del negocio frente a el tiempo de envío en su sitio web.

¿El tiempo de entrega es igual en zona urbana que en zona rural?




No, la zona rural es significativamente mas lenta. Al comparar las medianas mediante boxplots, se observa que la mediana rural (58.7 h) es cuatro veces mayor a la urbana. Deberia diferenciarse a nivel nacional y por zona o se generarán expectativas incumplidas en la zona rural.

¿Con qué transportadora se debe renegociar la tarifa?




Debe renegociarse la tarifa con Transpacífico, es el que tiene el costo más alto por kilómetro, además no tiene mejor tiempo ni la mejor tasa de devolución, su costo no se traduce en una ventaja competitiva en eficiencia o Calidad.

¿Sobre qué valor se debe tarifar el seguro de mercancía?




Sobre la Mediana (~117 mil COP) como base general del volumen, y tratar los envíos de alto valor declarado (outliers) con una póliza o recargo aparte, no con la tarifa estándar, la media (~2.1M COP) está inflada por un puñado de envíos de valor extremo (hasta 1.500M COP) que no son representativos de la operación típica.

¿Cuántas visitas hace la empresa por envío y dónde se concentran las repetidas?



1.35 visitas promedio, las repetidas se concentran en ciudades específicas. Aunque la mediana de intentos es de 1, el 28.3% de los envíos requiere reintentos. El EDA permite detectar una estructura de calidad local, las barras de error y tasas de reintento no son uniformes entre ciudades, lo que sugiere problemas en la calidad de datos en las direcciones y problemas específicos por ciudad.

¿Cuál canal de venta tiene mejor calificación del cliente?



Para el canal call center no se puede determinar por falta de datos, tiene 0% de cobertura de encuesta, ese canal no está siendo evaluado, por lo que no se puede afirmar nada sobre su satisfacción, y se debe corregir el proceso de encuesta ahí antes que nada. Entre los canales que sí se pueden comparar, Tienda propia obtiene la calificación promedio más alta frente a Marketplace, aunque la diferencia es pequeña, el control del canal propio se asocia con una mejor experiencia percibida.